




INTRODUÇÃO AO APRENDIZADO DE MÁQUINA

INSURANCE CHARGES (CUSTOS DE SEGURO)

Nome: Giovana Giovanin CP3026337

Nome :Maria Eduarda Ribeiro Padovani Loschi CP3025811

Introdução

- Origem dos Dados: Dataset "Medical Cost Personal Datasets" (Kaggle).
- Problema: Trata-se de uma tarefa de Regressão, onde o objetivo é prever uma variável numérica contínua.
- Variável Alvo (Target): charges (Custos médicos individuais faturados pelo seguro).
- Objetivo de Negócio: Identificar quais atributos (como IMC, idade e tabagismo) possuem maior poder preditivo para estimar o risco financeiro e o valor das apólices.



Preparação da base de dados

- Integridade do Dataset: Verificação realizada via Pandas para identificar inconsistências.
- Dados Faltantes: 0% de valores nulos; todas as 1.338 linhas estão preenchidas.
- Saneamento: Não houve necessidade de remoção de duplicatas ou correção de nomes de colunas.
- Tratamento de Outliers: Optamos por manter todos os registros, pois os valores extremos (custos altos) são reais e essenciais para o modelo de regressão entender riscos.


Library





Principais Descobertas da Análise

Distribuição de Custos Médicos: Fumantes vs. Não Fumantes



Distribuição de
Custos Médicos:
Fumantes vs. Não
Fumantes



Justificativa

Boxplot

comparar categorias

Motivo da escolha:

O Boxplot oferece uma visão imediata da mediana, da amplitude dos dados (tamanho da caixa) e da presença dos valores discrepantes, que são os valores atípicos da base.

O que ele prova:

Se usássemos apenas uma barra de média, não saberíamos que os custos dos fumantes variam tanto. O Boxplot mostra que ser fumante é um risco instável.

Analise do grafico

Custos Médios:

- Não Fumantes: ~\$8.434.
- Fumantes: ~\$32.050.



Fator Multiplicador:

O fumo eleva os gastos em quase 4 vezes .

Risco Atuarial:

Custos de fumantes são altamente imprevisíveis e dispersos.

A Interação IMC + Fumo (Dispersão)





Justificativa

Gráfico de Dispersão

ideal para ver a relação entre duas variáveis numéricas.

Motivo da escolha:

Ele permite ver, em um único olhar, a mediana (a linha central), a dispersão (o tamanho da caixa) e os outliers (pontos fora da curva).

O que ele prova:

Ele mostra que a correlação entre IMC e custo não é igual para todo mundo; ela é "potencializada" pelo cigarro.

Análise do gráfico


Momento crítico: $IMC > 30$ (Obesidade).

Impacto Combinado:

- Fumantes + Obesidade: Custos entre \$30k e \$60k.
- Fumantes + Peso Normal: Custos em torno de \$20k.

O IMC elevado potencializa o risco apenas em fumantes; não fumantes mantêm custos baixos mesmo com IMC alto.

Distribuição de Idade dos Segurados





Justificativa Histograma

relação entre duas variáveis numéricas.

Motivo da escolha:
Ele mostra a **frequência**. É melhor
que um gráfico de pizza porque
temos muitas idades diferentes.

O que ele prova:
Ele revela se a sua base de dados tem
mais jovens ou idosos, o que é
fundamental para saber se o seu
modelo de regressão será "viciado" em
um grupo específico.

Analise do grafico

Tendência Linear:

- O custo médico apresenta um crescimento gradual e constante conforme o avanço da idade (envelhecimento da carteira).

Representatividade da Base:


- Ampla cobertura de 18 a 64 anos, com um pico significativo de jovens adultos (18-19 anos) recém-ingressos no seguro.

Consistência de Dados:

- A distribuição uniforme nas demais faixas etárias garante que o modelo de previsão seja equilibrado para todas as idades.

Conclusões e Próximos Passos

- Fator Preponderante: O tabagismo é o fator de maior impacto isolado, elevando drasticamente a média e a incerteza financeira.
- Efeito Multiplicador: O custo não é apenas a soma de fatores; a combinação Fumo + IMC Alto gera um crescimento exponencial nos gastos.
- Foco no Comportamento: Variáveis demográficas (Sexo/Região) mostraram baixa relevância, provando que o estilo de vida dita o preço.
- Preparação para a Parte 2: As variáveis smoker, bmi e age serão os pilares para o treinamento do nosso modelo de Regressão.



Fim
Obrigada pela
atenção!!