




INTRODUÇÃO AO APRENDIZADO DE MÁQUINA


# INSURANCE CHARGES (CUSTOS DE SEGURO)

Nome: Giovana Giovanin CP3026337

Nome :Maria Eduarda Ribeiro Padovani Loschi CP3025811

# Revisão

- **Tabagismo** foi o fator de maior impacto.
- IMC elevado aumentou os custos.
- Idade apresentou correlação positiva com os gastos.
- Fumantes com IMC elevado apresentaram os maiores custos.



# Objetivo da Parte 2

- Construir modelos de Aprendizado de Máquina.
- Comparar diferentes algoritmos de regressão.
- Identificar o modelo com melhor desempenho.

# PREPARAÇÃO DOS DADOS

- Baseada na análise exploratória da etapa anterior
- Separação entre variáveis de entrada e variável alvo (charges)
- Divisão em treino e teste
- Padronização e codificação das variáveis

# MODELOS UTILIZADOS




# MODELOS UTILIZADOS

Regressão Linear: modelo base utilizado por ser simples, rápido e servir como referência inicial de desempenho

Random Forest: escolhido por ser um modelo mais robusto, capaz de capturar relações não lineares nos dados.

Gradient Boosting: utilizado por ser um modelo mais avançado, focado em reduzir erros e melhorar a precisão das previsões



# RESULTADOS DOS MODELOS

- O Gradient Boosting apresentou o menor erro médio (MAE)
- O Gradient Boosting apresentou o menor RMSE, indicando menos erros elevados
- O Gradient Boosting obteve o maior  $R^2$ , explicando aproximadamente 88% da variação dos custos médicos
- O Random Forest também apresentou desempenho superior à Regressão Linear
- Os modelos baseados em árvores superaram o modelo linear

| Modelo                           | MAE (Erro Médio) | RMSE    | $R^2$ Score (Precisão) |
|----------------------------------|------------------|---------|------------------------|
| Linear Regression (Baseline)     | 4181.19          | 5796.28 | 0.784                  |
| Random Forest                    | 2543.98          | 4567.78 | 0.866                  |
| Gradient Boosting (Ponto Extra!) | 2443.48          | 4329.57 | 0.879                  |

# Otimização do Random Forest


- O Random Forest foi selecionado por apresentar desempenho próximo ao melhor modelo da comparação inicial.
- Foi utilizada a técnica **Grid Search** para testar diferentes combinações de hiperparâmetros.
- O objetivo foi verificar se ajustes na configuração do modelo poderiam melhorar seus resultados.
- Após a otimização, observou-se uma pequena melhora no  $R^2$  e no RMSE.
- Mesmo após a otimização, o Gradient Boosting continuou apresentando o melhor desempenho geral.
- A etapa permitiu validar a escolha do modelo final e reforçar a confiabilidade dos resultados obtidos anteriormente.

| Métrica          | Resultado |
|------------------|-----------|
| MAE (Erro Médio) | 2.575,23  |
| RMSE             | 4.443,50  |
| $R^2$ Score      | 0,873     |



# Conclusão:

- O Gradient Boosting foi o modelo que apresentou o melhor desempenho entre os algoritmos avaliados.
- O modelo obteve os menores erros de previsão e o maior índice de precisão ( $R^2$ ).
- Os resultados demonstraram maior capacidade de identificar padrões e estimar corretamente os custos médicos.
- Para o problema estudado, o Gradient Boosting foi a técnica de Aprendizado de Máquina mais adequada para a previsão de custos em seguros de saúde.
- Dessa forma, o modelo se mostrou a melhor alternativa para apoiar estimativas de gastos médicos neste conjunto de dados.



**Fim**  
**Obrigada pela**  
**atenção!!**