




INTRODUÇÃO AO APRENDIZADO DE MÁQUINA


INSURANCE CHARGES (CUSTOS DE SEGURO)

Nome: Giovana Giovanin CP3026337

Nome :Maria Eduarda Ribeiro Padovani Loschi CP3025811


Revisão

- **Tabagismo** foi o fator de maior impacto.
- IMC elevado aumentou os custos.
- Idade apresentou correlação positiva com os gastos.
- Fumantes com IMC elevado apresentaram os maiores custos.



Objetivo da Parte 2

- Construir modelos de Aprendizado de Máquina.
- Comparar diferentes algoritmos de regressão.
- Identificar o modelo com melhor desempenho.



PREPARAÇÃO DOS DADOS

- Baseada na análise exploratória da etapa anterior
- Separação entre variáveis de entrada e variável alvo (charges)
- Divisão em treino e teste
- Padronização e codificação das variáveis


MODELOS UTILIZADOS

MODELOS UTILIZADOS

Regressão Linear: modelo base utilizado por ser simples, rápido e servir como referência inicial de desempenho

Random Forest: escolhido por ser um modelo mais robusto, capaz de capturar relações não lineares nos dados.

Gradient Boosting: utilizado por ser um modelo mais avançado, focado em reduzir erros e melhorar a precisão das previsões



RESULTADOS DOS MODELOS

- O Gradient Boosting apresentou o menor erro médio (MAE)
- O Gradient Boosting apresentou o menor RMSE, indicando menos erros elevados
- O Gradient Boosting obteve o maior R^2 , explicando aproximadamente 88% da variação dos custos médicos
- O Random Forest também apresentou desempenho superior à Regressão Linear
- Os modelos baseados em árvores superaram o modelo linear

Modelo	MAE (Erro Médio)	RMSE	R^2 Score (Precisão)
Linear Regression (Baseline)	4181.19	5796.28	0.784
Random Forest	2543.98	4567.78	0.866
Gradient Boosting (Ponto Extra!)	2443.48	4329.57	0.879


Otimização do Random Forest

- O Random Forest foi selecionado por apresentar desempenho próximo ao melhor modelo da comparação inicial.
- Foi utilizada a técnica **Grid Search** para testar diferentes combinações de hiperparâmetros.
- O objetivo foi verificar se ajustes na configuração do modelo poderiam melhorar seus resultados.
- Após a otimização, observou-se uma pequena melhora no R^2 e no RMSE.
- Mesmo após a otimização, o Gradient Boosting continuou apresentando o melhor desempenho geral.
- A etapa permitiu validar a escolha do modelo final e reforçar a confiabilidade dos resultados obtidos anteriormente.

Métrica	Resultado
MAE (Erro Médio)	2.575,23
RMSE	4.443,50
R^2 Score	0,873

Conclusão:

- O Gradient Boosting foi o modelo que apresentou o melhor desempenho entre os algoritmos avaliados.
- O modelo obteve os menores erros de previsão e o maior índice de precisão (R^2).
- Os resultados demonstraram maior capacidade de identificar padrões e estimar corretamente os custos médicos.
- Para o problema estudado, o Gradient Boosting foi a técnica de Aprendizado de Máquina mais adequada para a previsão de custos em seguros de saúde.
- Dessa forma, o modelo se mostrou a melhor alternativa para apoiar estimativas de gastos médicos neste conjunto de dados.



Fim
Obrigada pela
atenção!!